

# Modelos de reconocimiento automático de emociones: resultados preliminares de una revisión

Tesista: Díaz Barquinero, Agustín

**DNI**: 41710408

Tutor: D'Amelio, Tomás Ariel

**DNI del Tutor:** 38.991.529

Mail: agustindiazbarquinero@gmail.com

AGRADECIMIENTOS	2
INTRODUCCIÓN	3
Computación Afectiva y Reconocimiento de Emociones	3
Modelos emocionales	4
Modalidades de detección de emociones	4
Actividad electrodérmica, emociones y computación afectiva	5
Estado del arte	6
Preguntas de investigación	7
Objetivos del trabajo	7
Hipótesis	7
METODOLOGÍA	8
Pre-registro	8
Criterios de inclusión y exclusión	8
Fuentes de información	9
Estrategia de búsqueda	9
Proceso de selección	11
Proceso de recolección de datos	11
Datos extraídos	12
Evaluación del riesgo de sesgo del estudio	12
RESULTADOS	14
CONCLUSIÓN	18
BIBLIOGRAFÍA	20

# **AGRADECIMIENTOS**

A la cátedra II de Neurofisiología y todo su cuerpo docente, por permitirme dar mis primeros pasos en la docencia e investigación. En particular, al Lic. Tomas D'Amelio y al Lic. Manuel Correa Freisztav, quienes me han acompañado en estos últimos años.

A mis compañeros Emmanuel y Lorenzo, por haber trabajado juntos en el proyecto del cual se desprende la presente tesis.

A mi familia, por su apoyo incondicional.

Y a la universidad pública argentina, reafirmando mi compromiso y defensa por una educación pública, laica, no arancelada y de calidad.

## INTRODUCCIÓN

## Computación Afectiva y Reconocimiento de Emociones

La Computación Afectiva (CA) surge en la década de los 90' como un novedoso campo que busca incluir a las emociones en el estudio de la interacción humano-computador (HCI por sus siglas en inglés). Sus objetivos principales se podrían resumir en el reconocimiento de estados afectivos, su interpretación y cómo responder inteligentemente a ellos (Picard, 2000). Esto último consiste en dotar a las computadoras de habilidades emocionales para que puedan interactuar con sus usuarios en base a la detección de sus distintos estados afectivos.

Hoy en día la CA se constituye como un área de investigación consolidada y auspiciosa reuniendo a diversas disciplinas como la psicología, las ciencias computacionales, la neurociencia, la ingeniería, la educación, entre otras (Brigham, 2017; Calvo et al., 2015).

Dentro de la CA el reconocimiento de emociones se presenta como uno de los subcampos más populares y prometedores no sólo por sus aportes al entendimiento de la HCI, sino también por sus potenciales aplicaciones en diferentes poblaciones tanto clínicas como no clínicas. Desde los inicios de la CA ha habido un interés particular por perfeccionar el estudio y comprensión de las personas con Trastorno del Espectro Autista (el Kaliouby et al., 2006). De su estudio se han desprendido diversas y potenciales aplicaciones tanto para el diagnóstico como el tratamiento de poblaciones con TEA (el Kaliouby et al., 2006; Grabowski et al., 2019). Por ejemplo, la creación de sistemas interactivos que ayudan a niños a reconocer, entender y expresar emociones desarrollando así sus habilidades sociales (Rice et al., 2015) o el desarrollo de robots humanoides que a partir de diferentes indicios puedan reconocer automáticamente las emociones del niño y adaptarse a ellas (Goulart et al., 2014). Conjuntamente, Luneski et al. (2010), partiendo de la innegable relación entre la salud y las emociones, destacan la complementación de la CA con la Medicina Informática y los respectivos aportes que generarían en el cuidado y atención de la salud facilitando la prevención de enfermedades y el autocuidado y monitoreo de la salud.

Asimismo, en los últimos tiempos la CA ha dejado de tener un interés meramente académico y de salud manifestándose cada vez más en nuevos

productos, solicitudes de patentes, empresas emergentes, cursos universitarios y nuevos programas de financiación de agencias de todo el mundo (Calvo et al., 2015).

#### **Modelos emocionales**

Diversos modelos se han utilizado para el estudio de las emociones en el campo de la computación afectiva aunque es posible distinguir dos elementales: los modelos categoriales y los modelos dimensionales. En los primeros se encuentra el reconocido modelo de Paul Ekman y las 6 emociones básicas (alegría, tristeza, miedo, enojo, disgusto y sorpresa) (Ekman & Cordaro, 2011). Por otro lado, en los últimos años ha crecido el interés por los abordajes dimensionales los cuales se basan principalmente en el modelo bidimensional de los estados afectivos propuesto por Russell (1980). Este modelo, denominado "Modelo circumplejo de las Emociones", refiere a dos componentes fundamentales que caracterizan a las emociones: el *arousal* y la valencia. El *arousal* refiere a qué tan excitante o aburrida es una emoción y es medido de alto a bajo, mientras que la valencia refiere a qué tan agradable o desagradable es una emoción y se mide de positiva o negativa (Lang, 1995).

### Modalidades de detección de emociones

Asimismo, se pueden identificar principalmente dos modalidades de detección de estados afectivos. Por un lado, a partir de expresiones faciales, postura, discurso, lenguaje, entre otros. Por otro lado, en los últimos tiempos ha aumentado el interés por el uso de señales fisiológicas debido a que se suelen obtener más fácilmente y son menos sensibles a variabilidad social y cultural (Jang et al., 2014). Entre las más utilizadas se encuentran el electroencefalograma (EEG), electromiograma (EMG), electrocardiograma (ECG), ritmo cardíaco y actividad electrodérmica (EDA, del inglés *Electrodermal Activity*), entre otras (Shu et al., 2018).

## Actividad electrodérmica, emociones y computación afectiva

Dentro de estas medidas psicofisiológicas, la actividad electrodérmica (EDA) es una medida periférica que evalúa las propiedades eléctricas de la piel producto de la inervación de las glándulas sudoríparas por parte del sistema nervioso autónomo (SNA) (Boucsein, 2012). Si bien son diversas las funciones de estas glándulas, su activación en las zonas de la palma de la mano y la planta del pie ha sido de particular interés al estar principalmente relacionadas con el sudor emocional, esto es, el incremento de actividad producto de estímulos emocionales o situaciones de estrés (Asahina et al., 2015). Esto ha llevado a que la actividad de electrodérmica se convierta en una de las medidas más utilizadas para indicar el componente de *arousal* de las emociones en el campo de las ciencias afectivas (Sequeira et al., 2009).

A modo ejemplo, un modelo de reconocimiento de emociones convencional buscaría evaluar si existe una correspondencia entre las respuestas dadas por los participantes en un auto reporte afectivo (e.g. cuestionario SAM) y las señales de EDA que se tomaron durante una presentación de los estímulos en un experimento emocional. Para ello, se vincularía la información objetiva sobre fragmentos de señal EDA con la respuesta subjetiva al cuestionario SAM. Estaríamos partiendo desde un diseño cuasi-experimental donde las variables independientes serían aquellas features o características extraídas de la señales de EDA, mientras que la variable dependiente sería el componente arousal o excitación.

Un programa de computadora aprende una tarea si su *performance* o desempeño en ella mejora con la experiencia (James et al., 2013). Tal es así que en reconocimiento de emociones se pueden identificar:

- Tarea: reconocimiento de emociones/estados afectivos
- Medida de performance: Cantidad de ensayos en el que el algoritmo reconoció correctamente el estado afectivo del sujeto
- Experiencia: Base de datos con señales fisiológicas (EDA) de los sujetos y el estado afectivo autorreportado (e.g. cuestionario SAM)

Para un prototipo de los pasos de un modelo de aprendizaje automático ver figura 1.

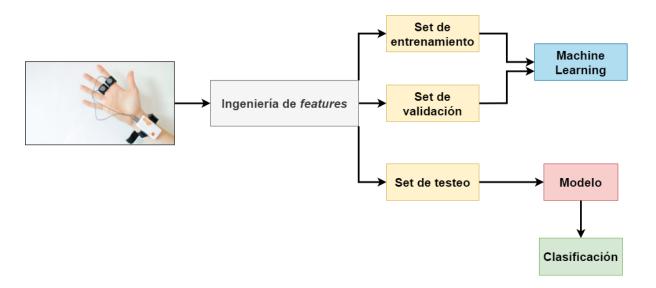


Figura 1: Diagrama de los pasos de un problema de aprendizaje automático

La ingeniería de *features* o características es una tarea esencial en la preparación de datos para un problema de aprendizaje automático. Implica la construcción de características adecuadas a partir de características dadas que conducen a un mejor desempeño predictivo. Incluye la aplicación de funciones de transformación, como operadores aritméticos y agregados, en características dadas para generar otras nuevas (Nargesian et al., 2017).

Si queremos testear un modelo sobre un set de datos u observaciones podríamos recurrir al Enfoque de Set de Validación. Este implica dividir aleatoriamente el conjunto disponible de observaciones en dos partes, un set de entrenamiento y un set de validación o set de reserva (James et al., 2013). El modelo se ajusta con el set de entrenamiento y ese modelo ajustado se usa para predecir las respuestas de las observaciones en el set de validación.

#### Estado del arte

Últimamente se han hecho grandes esfuerzos por aumentar la extracción de información a partir de tareas de procesamiento de señal, así como también con trabajo de ingeniería y selección de *features* en EDA, con el fin principal de maximizar el poder predictivo de dichos modelos (Posada-Quintero & Chon, 2020; Shukla et al., 2019). Sin embargo, poco énfasis se ha puesto en la literatura en comprender los modelos emocionales que subyacen a dichos sistemas de reconocimiento de estados afectivos con EDA y en el valor inferencial de dichos modelos de aprendizaje estadístico.

Se llevará a cabo una revisión sistemática de la literatura sobre el reconocimiento de emociones a partir de EDA. Se indagará principalmente las características propias del modelo afectivo utilizado. De forma secundaria, se explorarán las características de las mediciones de EDA y los modelos de aprendizaje estadístico utilizados para la tarea de reconocimiento automático. Se espera analizar características comunes en el estado del arte, y en base a ello realizar futuras recomendaciones en el campo.

Recientemente Maldonado (2021) y Galán (2021) presentaron resultados preliminares de los períodos 2018-2020 y 2010-2015, respectivamente. En esta ocasión se pretende abarcar toda la literatura publicada entre el 2010 y el 2020.

## Preguntas de investigación

¿Qué modelo de emociones es más utilizado para la predicción de estados afectivos con EDA?

¿Cuáles son las formas de elicitación existentes para generar estados afectivos?

¿Cuáles son las formas de uso y tendencias de uso de base de datos para el reconocimiento automático de emociones con EDA?

### Objetivos del trabajo

Los objetivos del presente trabajo son: indagar en la literatura sobre reconocimiento de emociones a partir de EDA, extraer tendencias de los datos recabados y, en lo posible, poder dar recomendaciones en base a los resultados obtenidos.

## **Hipótesis**

Al pasar del tiempo hay un predominio en el uso de modelos dimensionales de emociones por sobre otros modelos posibles.

Existe un predominio en el uso de los estímulos visuales y auditivos para la generación de estados afectivos.

Con el paso del tiempo el uso de base de datos públicas para reconocimiento de emociones es más frecuente. Sin embargo, hay un predominio de base de datos propios generados por los mismos autores.

# **METODOLOGÍA**

Esta revisión se llevó a cabo siguiendo los pasos y recomendaciones de la declaración PRISMA (Page et al., 2021).

## Pre-registro

En los últimos años el interés y la preocupación por la replicabilidad en la ciencia ha aumentado notablemente (Munafò et al., 2017). En pos de seguir las buenas prácticas de ciencia abierta y de evitar sesgos de publicación se procedió a registrar el plan del presente trabajo en el repositorio web *Open Science Framework* (OSF) (https://osf.io/) previo a ser llevado a cabo. OSF es una aplicación web gratuita de código abierto que busca conectar y respaldar el trabajo de investigación, permitiendo y promoviendo la eficiencia, eficacia y reproducibilidad de los trabajos científicos.

### Criterios de inclusión y exclusión

Se incluyeron:

- Estudios que incluyan uno o múltiples modelos de aprendizaje estadístico para el reconocimiento afectivo con EDA. En caso de que un mismo artículo evalúe más de un modelo y los mismos difieran por alguna de las variables de interés de la revisión (e.g. base datos, algoritmo, tipo de *output*) se procederá a ingresar a cada uno de ellos como una nueva instancia o modelo a evaluar. En cambio, en caso de que los modelos difieran en el manejo e ingeniería de *features* se ingresará aquel que presente la mejor *performance*, por no ser una variable de interés en esta revisión.
- Estudios tanto en inglés como en español
- Estudios focalizados en muestras no clínicas

## Se excluyeron:

- Capítulos de libros, revisiones, metaanálisis, comentarios, tesis de maestría y doctorado, descripciones de talleres y resúmenes de reuniones.
- Trabajos que se focalizan en poblaciones clínicas.
- Trabajos que se focalizan en modelos animales.
- Estudios que incluyan únicamente modelos entrenados con señales multimodales (e.g. EDA y HRV). Sin embargo, si en un mismo trabajo se entrenan distintos modelos, y uno o más de ellos utiliza features únicamente de EDA, estos serán incorporados para análisis posteriores. Trabajos que creen herramientas de software (excepto que los mismos sean softwares de reconocimiento de emociones y sean testeados de acuerdo a los criterios establecidos en la presente revisión).

#### Fuentes de información

Se revisaron las bases de datos Scopus y PubMed, y se seleccionaron artículos de revistas, conferencias y preimpresiones, entre el 1 de enero del 2010 y el 31 de diciembre del 2020. En caso de existir artículos en sus dos versiones, se privilegiaron las publicaciones que hayan sido revisadas por pares posterior a la preimpresión.

### Estrategia de búsqueda

Las siguientes palabras claves fueron utilizadas al realizar las búsquedas en las bases de datos de *Pubmed* y *Scopus*: *EDA* o *Electrodermal Activity* o *GSR* o *Galvanic Skin Response* o *Skin conductance* o *SCR* o *SCL* y *Emotions* o *Emotion* o *Affective y Recognition* o *Decoding* o *Detection* o *Classification* o *Regression*. Estas búsquedas se realizaron en el título, abstract y palabras clave de los artículos.

## Búsqueda en PubMed:

OR ((EDA[Title/Abstract]) OR (electrodermal activity[Title/Abstract]) (GSR[Title/Abstract]) OR (galvanic skin response[Title/Abstract]) OR (skin conductance[Title/Abstract]) OR (SCR[Title/Abstract]) OR (SCL[Title/Abstract])) AND ((emotion[Title/Abstract]) OR (affective[Title/Abstract])) AND ((recognition[Title/Abstract]) (decoding[Title/Abstract]) OR OR (detection[Title/Abstract]) OR (classification[Title/Abstract]) OR (regression[Title/Abstract]))

La búsqueda se realizó en *títulos y abstracts* (no se realizó búsqueda en keywords ya que esta base de datos no ofrece la opción). En los criterios de búsqueda avanzada se introdujo: humans; *lenguage:* english, spanish; *years:* 2010 - 2020.

## Búsqueda en Scopus

( TITLE-ABS-KEY ( eda ) OR TITLE-ABS-KEY ( "electrodermal activity" ) OR TITLE-ABS-KEY (gsr ) OR TITLE-ABS-KEY ("galvanic skin response") OR TITLE-ABS-KEY ( "skin conductance" ) OR TITLE-ABS-KEY ( scr ) TITLE-ABS-KEY (scl)) AND (TITLE-ABS-KEY (emotion\*) OR TITLE-ABS-KEY ( affective ) ) AND ( TITLE-ABS-KEY ( recognition ) OR TITLE-ABS-KEY ( decoding) OR TITLE-ABS-KEY (detection) OR TITLE-ABS-KEY (classification) OR TITLE-ABS-KEY (regression)) AND (LIMIT-TO (PUBYEAR, 2020) OR LIMIT-TO (PUBYEAR, 2019) OR LIMIT-TO (PUBYEAR, 2018) OR LIMIT-TO ( PUBYEAR, 2017) OR LIMIT-TO (PUBYEAR, 2016) OR LIMIT-TO (PUBYEAR . 2015 ) OR LIMIT-TO (PUBYEAR . 2014 ) OR LIMIT-TO (PUBYEAR . 2013 ) OR LIMIT-TO (PUBYEAR, 2012) OR LIMIT-TO (PUBYEAR, 2011) OR LIMIT-TO (PUBYEAR, 2010)) AND (LIMIT-TO (SRCTYPE, "j") OR LIMIT-TO (SRCTYPE, "p")) AND (LIMIT-TO (LANGUAGE, "English")) AND ( LIMIT-TO (DOCTYPE, "ar") OR LIMIT-TO (DOCTYPE, "cp"))

La búsqueda se realizó en *títulos*, *abstracts y* palabras clave. En los criterios de búsqueda avanzada se introdujo: 2010- 2020; *source type:* journal, conference proceeding; *document type: article, conference artículo; language: english;* Fecha de las búsquedas: 21 de febrero de 2021.

#### Proceso de selección

El proceso de selección se dividió en dos partes.

En primera insancia, luego de recopilar los registros, se exportaron a la herramienta Rayyan, una aplicación web y móvil gratuita para llevar a cabo revisiones sistemáticas, con el fin de ayudar a agilizar la selección inicial de resúmenes y títulos (Ouzzani et al., 2016). Allí se eliminaron duplicados y se dividió la cantidad total entre los investigadores, para luego dar inicio al proceso de filtrado de los artículos. Se comenzó buscando en títulos, abstracts y keywords discrepancias con los criterios de inclusión y exclusión. Luego, cada investigador revisó las clasificaciones realizadas por otro autor (doble check). Se resolvieron en conjunto las posibles discrepancias y por último se anotaron la cantidad de artículos excluidos y el motivo.

En una segunda fase, se exportaron los artículos restantes a Zotero, un software gratuito de código abierto y una herramienta de gestión web que organiza fuentes digitales y bibliografías (Idri, 2015). Allí se dividieron artículos equitativamente entre los investigadores. Luego, se leyeron los trabajos completos, siendo descartados los artículos desalineados con los criterios. Para ello, se llevaron a cabo múltiples lecturas de los trabajos en búsqueda de dimensiones particulares, y se anotó cuántas se descartan en cada paso.

### Proceso de recolección de datos

Una vez descartados los artículos que no cumplían con los criterios, cada investigador procedió a extraer los datos de todos los modelos de reconocimiento hallados en los artículos que le fueron asignados que cumplan con los criterios establecidos (ver apartado de Criterios de Elegibilidad). Los mismos se clasificaron en nueve ocho categorías para su posterior análisis (ver apartado de Datos extraídos).

En un primer momento cada investigador clasificó los modelos a incluir de los artículos que le fueron asignados, para pasar luego a un nuevo doble check donde otro investigador distinto al de la primera etapa revisó sus artículos, en búsqueda de un consenso en la clasificación. Terminado esto, se resolvieron en conjunto los conflictos existentes. Una vez allí, se procedió con el análisis de los datos obtenidos

de esta clasificación.

### **Datos extraídos**

Se creó una base de datos compartida entre los investigadores, donde se clasificó cada artículo según los siguientes criterios (tentativos): (ver tabla 1)

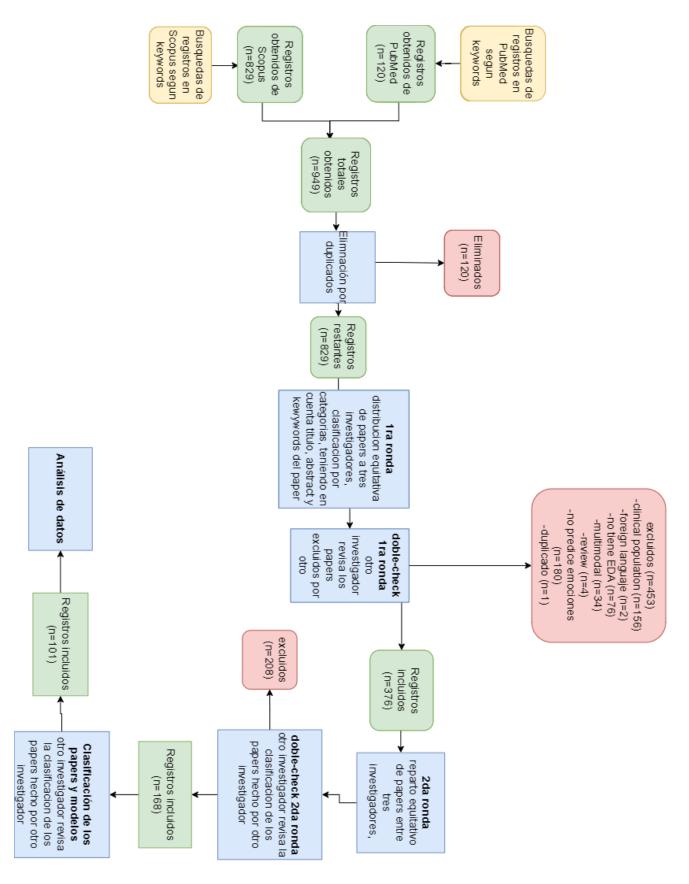
Tabla 1.

Categorías de datos empleadas en la clasificación de los trabajos

Cutogoriae de dates empleadas em la sidemadeien de los trabajos		
Metadata	Datos sobre autores, título, año de publicación, journal donde se ha publicado, tipo de articulo, país de afiliación primer autor)	
Tipo de data	El tipo de base de datos empleada en la realización del trabajo (si es una creada de forma original, o si se trabajó con una base de datos pública	
Participantes	Características relevantes de la muestra: tamaño, sexos, rango de edad, país de origen, etc.	
Técnica de estimulación afectiva	El tipo de estímulo ha sido empleado en los experimentos realizados, su tiempo de exposición (visual, auditivo, visual-auditivo, o cualquier tipo que pueda ser encontrado en los trabajos)	
Autoreporte	si se ha usado, cuál tipo se ha usado, modelo de emoción usado	
EDA	Dispositivo utilizado, localización de los sensores, etc	
Modelo de emociones	Cuál fue el modelo teórico de emociones empleado en la realización del trabajo (dimensional si se ha empleado las dimensiones de valence, arousal, u otras; o categorial si se ha empleado el estudio de emociones como ser estrés, felicidad, tristeza, neutral, etc.).	
Modelos de aprendizaje estadístico con sus respectivas medidas de performance	output del modelo usado, tipo de modelo, tipo de diseño	

## Evaluación del riesgo de sesgo del estudio

Cada artículo en cada ronda fue revisado dos veces por dos investigadores distintos, en búsqueda de discrepancias en la clasificación e inclusión de los mismos, usando las herramientas de Rayyan y Zotero. De existir discrepancias, fueron anotadas y resueltas en conjunto con todo el equipo.



**Figura 2. Diagrama de flujo de la revisión.** Se muestra la recabación primero de los datos, su eliminación por duplicados, su filtrado en dos etapas y el análisis de los datos obtenidos.

#### **RESULTADOS**

Luego de los distintos procesos de filtrado, chequeo y revisión por parte de otros investigadores un total de 101 artículos fueron incluídos (ver Diagrama de flujo presente en la figura 2). A su vez, el número de modelos incluídos fue de 501 (recordar que si un mismo artículo evaluaba más de un modelo y los mismos diferían por alguna de las variables de interés de la revisión se ingresaba a cada uno de ellos como una nueva instancia o modelo a evaluar).

Para realizar el análisis de los datos se evaluaron las distintas características del apartado Datos extraídos según el artículo y no según el modelo. Esto es, se tomó un valor por artículo. Ahora bien, en caso de existir en el mismo artículo más de un modelo que difiera por alguna de las variables de interés se lo tuvo en cuenta como una nueva instancia también al momento de analizar los datos). Tanto para el procesamiento como el análisis de los datos se utilizó el lenguaje de programación Python 3 (Rossum y Drake, 2009).

Con respecto a la técnica de elicitación de emociones en 87 instancias de nuestro interés se pudo hallar diferenciación entre tarea pasiva y tarea activa: 67 pertenecían a las primeras mientras que sólo 20 a tareas activas.

En ocasiones, los investigadores suelen usar técnicas estandarizadas para elicitar las emociones en los sujetos experimentales. Se hallaron 11 técnicas estandarizadas diferentes que fueron utilizadas en 24 ocasiones (ver figura 3).

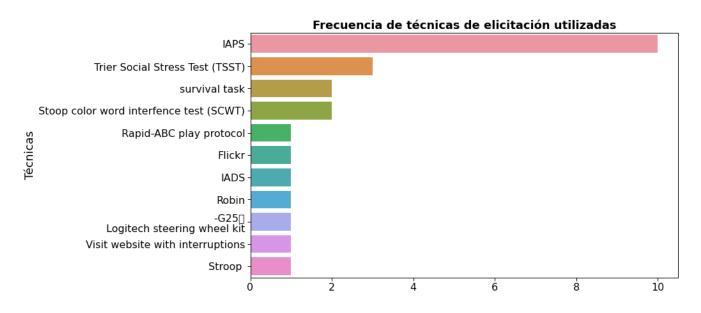


Figura 3: Frecuencia de las técnicas estandarizadas de elicitación de emociones

En otras técnicas utilizadas no estandarizadas se halló: manejo e interacciones sociales en 4 ocasiones cada una, meditación en 2, y realidad virtual, lectura, UX y videojuegos en 1 ocasión cada una.

Es posible dividir la modalidad de estimulación en: modalidad visual, modalidad auditiva, modalidad somatosensorial y modalidad múltiple (visual y auditiva). De un total de 102 instancias a evaluar se halló que aproximadamente un 60% pertenecen a la modalidad múltiple, es decir, la tecnica de elicitación incluía aspectos visuales y auditivos, un 24.5% a modalidad visual, un 14.7% a modalidad auditiva y tan solo una ocasión (1%) para modalidad somatosensorial.

Con respecto a los dispositivos de medición de actividad electrodérmica utilizados se encontró que entre los 101 artículos incluídos se utilizaron 25 dispositivos de empresas o marcas diferentes en un total de 93 ocasiones. Biosemi Active Two , BIOPAC y Shimmer lideran la cantidad de usos con 18,17 y 16 respectivamente, representando más del 50% de la totalidad (Ver figura 4).

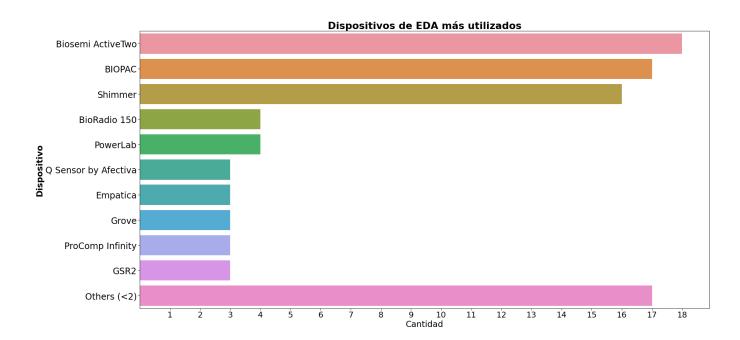


Figura 4: Dispositivos de medición de actividad electrodérmica

Por otro lado, con respecto a los datos utilizados se indagó si los investigadores recurrían a bases de datos públicas para entrenar a sus modelos o si generaban sus propios datos y cómo fue variando con el correr de los años (ver figura 5).

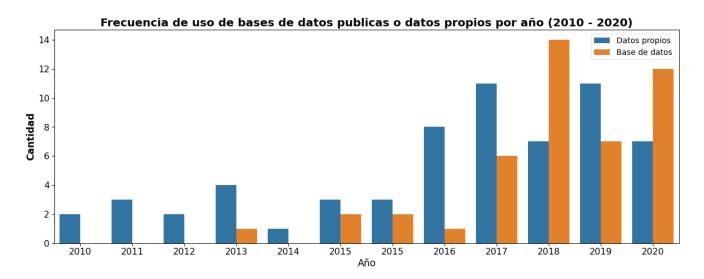


Figura 5: Gráfico de barra por año (2010-2020) según tipos de base de datos (privada, datos propios)

A su vez, se indagó cuáles son las bases de datos más frecuentes. Del total de 48 veces que se utilizaron bases de datos en 11 ocasiones fueron DEAP (Koelstra et al., 2012), en 10 MAHNOB (Soleymani et al., 2012) y en 9 AMIGOS (Miranda-Correa et al., 2021), concentrando el 62,5% de la totalidad. (ver figura 6).

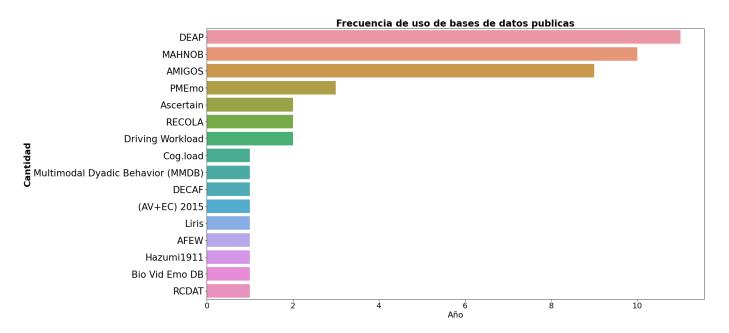


Figura 6: Frecuencia de uso de bases de datos.

Sobre los modelos afectivos utilizados se halló que un 63.3% recurrió a modelos dimensionales mientras que un 36.7% a modelos categoriales. A su vez, se indagó cómo fue variando con el tiempo el uso de los distintos modelos (ver figura 7)

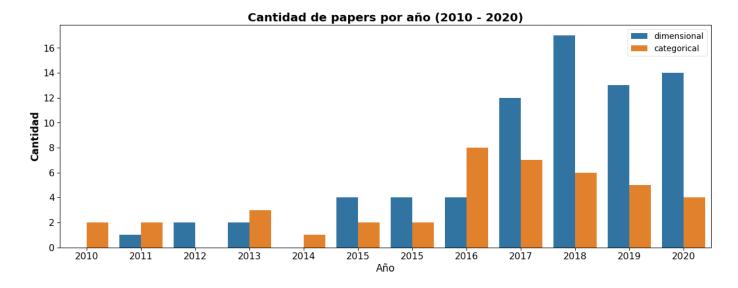


Figura 7: Gráfico de barra por año (2010-2020) por artículo según modelos de emociones empleado (categoriales o dimensionales)

# CONCLUSIÓN

Se llevó a cabo una revisión sistemática siguiendo los pasos establecidos por la declaración de PRISMA (Page et al., 2021) con el fin de indagar en la literatura sobre reconocimiento de emociones a partir de EDA y extraer tendencias de los datos recabados. Cabe destacar que la actividad electrodérmica particularmente se constituye como una medida ambulatoria, que interfiere poco con actividades de la vida diaria, económica y sencilla de tomar y analizar lo que refleja por qué mucha literatura sobre reconocimiento de emociones utiliza esta señal como input.

Para la extracción de los datos se crearon categorías de datos para su clasificación (Tabla 1). En esta ocasión, no obstante, se presentaron sólo resultados preliminares de algunas de esas categorías existentes. Un total de 101 artículos y 501 modelos fueron incluídos finalmente en el trabajo.

Se esperaba hallar un predominio de uso de estímulos visuales y auditivos para la generación de los estados afectivos. Se halló que un 99% de la estimulación fue visual, auditiva o ambas (múltiple). Asimismo, la gran mayoría de las bases de datos (Figura 6) utilizadas en el campo del reconocimiento de emociones constan de datos fisiológicos obtenidos a partir de la presentación de estímulos emocionales (i.e imágenes, videos, música, sonidos) en un ambiente de laboratorio (Abadi et al., 2015; Katsigiannis & Ramzan, 2018; Koelstra et al., 2012; Miranda-Correa et al., 2021; Soleymani et al., 2012; Subramanian et al., 2018). Esta forma de elicitación y de adquisición de datos le otorga al investigador un completo control sobre los datos recolectados. Sin embargo, sabemos que los datos generados en un contexto experimental de laboratorio no suelen generalizarse adecuadamente a ambientes naturales y situaciones de la vida cotidiana (Larradet et al., 2020) lo que en ocasiones obstaculiza el traslado de los conocimientos y los modelos entrenados a sus campos de aplicación más clínicos y sociales. Un aumento del uso de bases de datos fuera de ambientes de laboratorio como RECOLA (Ringeval et al., 2013), DRIVING WORKLOAD y MMDB (Rehg et al., 2013) facilitaría la extrapolación de los modelos a entornos más naturales y, por ende, a sus aplicaciones más prácticas. Por ejemplo, recientemente investigadores han desarrollado K-EmoCon (Park et al., 2020), una base de datos multimodal con registros de datos de emociones continuas durante un contexto natural como las interacciones sociales a partir de dispositivos de bajo costo "Off-the-Shelf", con el mismo fin.

Se esperaba que con el paso del tiempo el uso de base de datos públicas para reconocimiento de emociones sea más frecuente aunque continúe habiendo un predominio de datos propios generados por los mismos autores. Esto mismo se ve reflejado en la figura 5, donde podemos notar como van aumentando los modelos dimensionales a medida que se avanza en el tiempo. No obstante, la mayoría siguen siendo datos propios (un 57,8% de las instancias evaluadas desde 2010 a 2020 son a partir de datos generados por los mismos investigadores). En tiempos donde la replicabilidad de la ciencia es un problema cada vez más alarmante (Munafò et al., 2017), optar por bases de datos públicas podría ser una forma de contrarrestar estos problemas promoviendo el fácil acceso, la transparencia y la reproducibilidad de los resultados en el campo de reconocimiento de emociones. A su vez, se halló un porcentaje menor de uso de técnicas estandarizadas para elicitar los estados afectivos. Esto también se constituye como una barrera al momento de pensar la replicación de los resultados.

Al mismo tiempo, se esperaba que al pasar el tiempo hubiera un predominio en el uso de modelos dimensionales de emociones por sobre otros modelos posibles. Lo mismo fue reflejado en los resultados del presente trabajo, con un claro aumento de los modelos dimensionales en los últimos años por sobre los categoriales (ver figura 7).

El presente trabajo incluyó solamente trabajos unimodales de EDA para el reconocimiento automático de emociones. Se desprende para futuras investigaciones la posibilidad de incluir perspectivas multimodales con Ritmo Cardíaco, otra medida fisiológica económica, ambulatoria y sencilla de tomar y analizar, para tareas de este tipo.

## **BIBLIOGRAFÍA**

- Abadi, M. K., Ramanathan, S., Kia, S. M., Avesani, P., Patras, I., & Sebe, N. (2015).
  DECAF: MEG-Based Multimodal Database for Decoding Affective
  Physiological Responses. *IEEE Transactions on Affective Computing*.
  https://doi.org/10.1109/TAFFC.2015.2392932
- Asahina, M., Poudel, A., & Hirano, S. (2015). Sweating on the palm and sole:

  Physiological and clinical relevance. *Clinical Autonomic Research: Official Journal of the Clinical Autonomic Research Society*, *25*(3), 153-159. https://doi.org/10.1007/s10286-015-0282-1
- Boucsein, W. (2012). *Electrodermal Activity*. Springer Science & Business Media.
- Brigham, T. J. (2017). Merging Technology and Emotions: Introduction to Affective Computing. *Medical Reference Services Quarterly*, *36*(4), 399-407. https://doi.org/10.1080/02763869.2017.1369289
- Calvo, R. A., D'Mello, S., Gratch, J. M., & Kappas, A. (2015). *The Oxford Handbook of Affective Computing*. Oxford University Press.
- Ekman, P., & Cordaro, D. (2011). What is Meant by Calling Emotions Basic. *Emotion Review*, 3(4), 364-370. https://doi.org/10.1177/1754073911410740
- el Kaliouby, R., Picard, R., & Baron-Cohen, S. (2006). Affective computing and autism. *Annals of the New York Academy of Sciences*, 1093, 228-248. https://doi.org/10.1196/annals.1382.016
- Galán, L.A. (2021). Revisión sistemática sobre el reconocimiento automático de estados afectivos que utilizan actividad electrodérmica desde el 2010 hasta el 2015
- Goulart, C., Castillo, J., Valadão, C., Bastos, T., & Caldeira, E. (2014). EEG analysis and mobile robot as tools for emotion characterization in autism. *BMC*

- Proceedings, 8(4), P85. https://doi.org/10.1186/1753-6561-8-S4-P85
- Grabowski, K., Rynkiewicz, A., Lassalle, A., Baron-Cohen, S., Schuller, B., Cummins, N., Baird, A., Podgórska-Bednarz, J., Pieniążek, A., & Łucka, I. (2019). Emotional expression in psychiatric conditions: New technology for clinicians. *Psychiatry and Clinical Neurosciences*, 73(2), 50-62. https://doi.org/10.1111/pcn.12799
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An Introduction to Statistical Learning* (Vol. 103). Springer. https://doi.org/10.1007/978-1-4614-7138-7
- Jang, E.-H., Park, B.-J., Kim, S.-H., Chung, M.-A., Park, M.-S., & Sohn, J.-H. (2014).
  Emotion classification based on bio-signals emotion recognition using machine learning algorithms. 2014 International Conference on Information Science, Electronics and Electrical Engineering, 3, 1373-1376.
  https://doi.org/10.1109/InfoSEEE.2014.6946144
- Katsigiannis, S., & Ramzan, N. (2018). DREAMER: A Database for Emotion Recognition Through EEG and ECG Signals From Wireless Low-cost Off-the-Shelf Devices. *IEEE Journal of Biomedical and Health Informatics*, 22(1), 98-107. https://doi.org/10.1109/JBHI.2017.2688239
- Koelstra, S., Muhl, C., Soleymani, M., Jong-Seok Lee, Yazdani, A., Ebrahimi, T., Pun, T., Nijholt, A., & Patras, I. (2012). DEAP: A Database for Emotion Analysis; Using Physiological Signals. *IEEE Transactions on Affective Computing*, 3(1), 18-31. https://doi.org/10.1109/T-AFFC.2011.15
- Lang, P. J. (1995). The emotion probe. Studies of motivation and attention. *The American Psychologist*, 50(5), 372-385. https://doi.org/10.1037//0003-066x.50.5.372

- Larradet, F., Niewiadomski, R., Barresi, G., Caldwell, D. G., & Mattos, L. S. (2020).

  Toward Emotion Recognition From Physiological Signals in the Wild:

  Approaching the Methodological Issues in Real-Life Data Collection. *Frontiers*in Psychology, 11. https://doi.org/10.3389/fpsyg.2020.01111
- Luneski, A., Konstantinidis, E., & Bamidis, P. D. (2010). Affective medicine. A review of affective computing efforts in medical informatics. *Methods of Information in Medicine*, 49(3), 207-218. https://doi.org/10.3414/ME0617
- Maldonado, E. (2021). Revisión sistemática de modelos de reconocimiento automático de afectos a través de actividad electrodérmica
- Miranda-Correa, J. A., Abadi, M. K., Sebe, N., & Patras, I. (2021). AMIGOS: A Dataset for Affect, Personality and Mood Research on Individuals and Groups. *IEEE Transactions on Affective Computing*, 12(2), 479-493. https://doi.org/10.1109/TAFFC.2018.2884461
- Munafò, M. R., Nosek, B. A., Bishop, D. V. M., Button, K. S., Chambers, C. D., Percie du Sert, N., Simonsohn, U., Wagenmakers, E.-J., Ware, J. J., & Ioannidis, J. P. A. (2017). A manifesto for reproducible science. *Nature Human Behaviour*, 1(1), Art. 1. https://doi.org/10.1038/s41562-016-0021
- Nargesian, F., Samulowitz, H., Khurana, U., Khalil, E. B., & Turaga, D. (2017).

  Learning Feature Engineering for Classification. 2529-2535.
- Page, M. J., McKenzie, J. E., Bossuyt, P. M., Boutron, I., Hoffmann, T. C., Mulrow, C. D., Shamseer, L., Tetzlaff, J. M., Akl, E. A., Brennan, S. E., Chou, R., Glanville, J., Grimshaw, J. M., Hróbjartsson, A., Lalu, M. M., Li, T., Loder, E. W., Mayo-Wilson, E., McDonald, S., ... Moher, D. (2021). The PRISMA 2020 statement: An updated guideline for reporting systematic reviews. *BMJ (Clinical Research Ed.)*, 372, n71. https://doi.org/10.1136/bmj.n71

- Park, C. Y., Cha, N., Kang, S., Kim, A., Khandoker, A. H., Hadjileontiadis, L., Oh, A., Jeong, Y., & Lee, U. (2020). K-EmoCon, a multimodal sensor dataset for continuous emotion recognition in naturalistic conversations. *Scientific Data*, 7(1), 293. https://doi.org/10.1038/s41597-020-00630-y
- Picard, R. W. (2000). Affective Computing. MIT Press.
- Posada-Quintero, H. F., & Chon, K. H. (2020). Innovations in Electrodermal Activity

  Data Collection and Signal Processing: A Systematic Review. *Sensors (Basel, Switzerland)*, 20(2). https://doi.org/10.3390/s20020479
- Rehg, J., Abowd, G., Rozga, A., Romero, M., Clements, M., Sclaroff, S., Essa, I., Ousley, O., Li, Y., Kim, C., Rao, H., Kim, J., Lo Presti, L., Zhang, J., Lantsman, D., Bidwell, J., & Ye, Z. (2013). *Decoding Children's Social Behavior*. 3414-3421.
  - https://openaccess.thecvf.com/content\_cvpr\_2013/html/Rehg\_Decoding\_Childrens\_Social\_2013\_CVPR\_paper.html
- Rice, L. M., Wall, C. A., Fogel, A., & Shic, F. (2015). Computer-Assisted Face Processing Instruction Improves Emotion Recognition, Mentalizing, and Social Skills in Students with ASD. *Journal of Autism and Developmental Disorders*, 45(7), 2176-2186. https://doi.org/10.1007/s10803-015-2380-2
- Ringeval, F., Sonderegger, A., Sauer, J., & Lalanne, D. (2013). Introducing the RECOLA multimodal corpus of remote collaborative and affective interactions.

  2013 10th IEEE International Conference and Workshops on Automatic Face and Gesture Recognition (FG), 1-8. https://doi.org/10.1109/FG.2013.6553805
- Russell, J. A. (1980). A circumplex model of affect. *Journal of Personality and Social Psychology*, 39(6), 1161-1178. https://doi.org/10.1037/h0077714
- Sequeira, H., Hot, P., Silvert, L., & Delplanque, S. (2009). Electrical autonomic

- correlates of emotion. *International Journal of Psychophysiology*, *71*(1), 50-56. https://doi.org/10.1016/j.ijpsycho.2008.07.009
- Shu, L., Xie, J., Yang, M., Li, Z., Li, Z., Liao, D., Xu, X., & Yang, X. (2018). A Review of Emotion Recognition Using Physiological Signals. Sensors (Basel, Switzerland), 18(7). https://doi.org/10.3390/s18072074
- Shukla, J., Barreda-Angeles, M., Oliver, J., Nandi, G. C., & Puig, D. (2019). Feature

  Extraction and Selection for Emotion Recognition from Electrodermal Activity.

  IEEE Transactions on Affective Computing, 1-1.

  https://doi.org/10.1109/TAFFC.2019.2901673
- Soleymani, M., Lichtenauer, J., Pun, T., & Pantic, M. (2012). A Multimodal Database for Affect Recognition and Implicit Tagging. *IEEE transactions on affective computing*, 3(1), 42-55. https://doi.org/10.1109/T-AFFC.2011.25
- Subramanian, R., Wache, J., Abadi, M. K., Vieriu, R. L., Winkler, S., & Sebe, N. (2018). Ascertain: Emotion and personality recognition using commercial sensors. *IEEE Transactions on Affective Computing*, 9(2), 147-160.
- Van Rossum, G., & Drake, F. L. (2009). Python 3 Reference Manual. *Scotts Valley,*CA: CreateSpace.